Proyecto Reglas Asociación

Juan Alcaraz Otón, Óscar Camacho Barreda

Qualitative Bankruptcy Data Set

Utilizaremos UNA VERSIÓN PARECIDA PERO NO IGUAL del conjunto de datos `Qualitative_Bankruptcy Data Set` del repositorio *UCI Machine Learning* para trabajar el estudio de las variables Categóricas/Cualitativas y la bondad de las reglas de Asociación para extraer conocimiento de un conjunto de datos, en este caso, predecir la bancarrota (*Bankruptcy*) en base a parámetros cuantitativos/cualitativos preparados por expertos.

Cargar el fichero `Qualitative_Bankruptcy.num.txt` y crear el `data.frame QB`.

```r
#solucion

rm(list=ls())

library(arules)
```

```
## Warning: package 'arules' was built under R version 4.5.2

## Cargando paquete requerido: Matrix

##
## Adjuntando el paquete: 'arules'

## The following objects are masked from 'package:base':
##
##     abbreviate, write
```

```r
library(readr)

QB <- read_csv("Qualitative_Bankruptcy.num.txt", col_names = FALSE)
```

```
## Rows: 250 Columns: 7

## -- Column specification --------------------------------------------------------
## Delimiter: ","
## chr (1): X7
## dbl (6): X1, X2, X3, X4, X5, X6
##
## i Use `spec()` to retrieve the full column specification for this data.
## i Specify the column types or set `show_col_types = FALSE` to quiet this message.
```

Asigna nombres válidos a las columnas del `data.frame` (usa `make.names` para asegurarte que no contiene símbolos raros). Más información en el fichero `Qualitative_Bankruptcy.info.txt`

```
colnames(QB) <- make.names(c("Industrial Risk", "Management Risk",
                             "Financial Flexibility","Credibility",
                             "Competitiveness", "Operating Risk",
                             "Bankruptcy"))
```

Sabiendo que las variables numéricas representan un valor entre 0 y 10 para indicar la valoración del experto de cada variable, prueba a discretizar las variables numéricas en 3 factores ordenados **QB** de ***manera no supervisada*** para estimar la clase (`Bankruptcy`). La etiqueta asociada a valores bajos será "N" de valoración "negative", la etiqueta de valores altos será "P" de "positive" y el resto corresponderá a etiqueta "A" de "average".

```
#solucion

# Pasamos la columna de Bankruptcy a factor
QB$Bankruptcy <- as.factor(QB$Bankruptcy)

# Obtenemos los índices de columnas numéricas y sus nombres
cols_num <- sapply(QB,is.numeric)
nombres_num <- names(QB)[cols_num]

for(col_name in nombres_num){

  # Extraemos el vector numérico original de la columna
  vec_num <- QB[[col_name]]

  # Dibujamos el histograma
  hist(vec_num,
       breaks = 10,
       main = paste("Discretización de", col_name),
       xlab = "Valoración",
       col = "lightblue")

  # Calculamos los cortes entre los factores sobre el vector original
  cortes <- discretize(vec_num, method = "interval", breaks = 3, onlycuts = TRUE)

  # Dibujamos las líneas
  abline(v = cortes, col = "red")
}
```

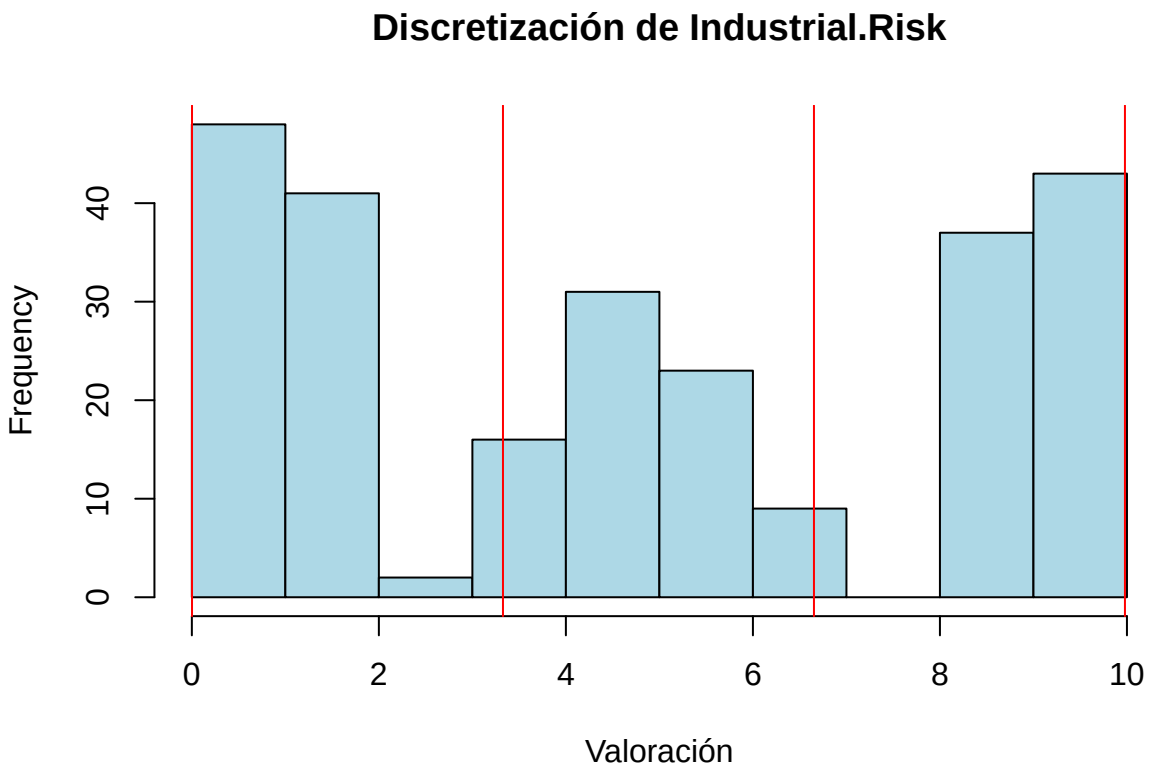
Discretización de Industrial.Risk
Frequency
0
10
20
30
40
0
2
4
6
8
10
Valoración

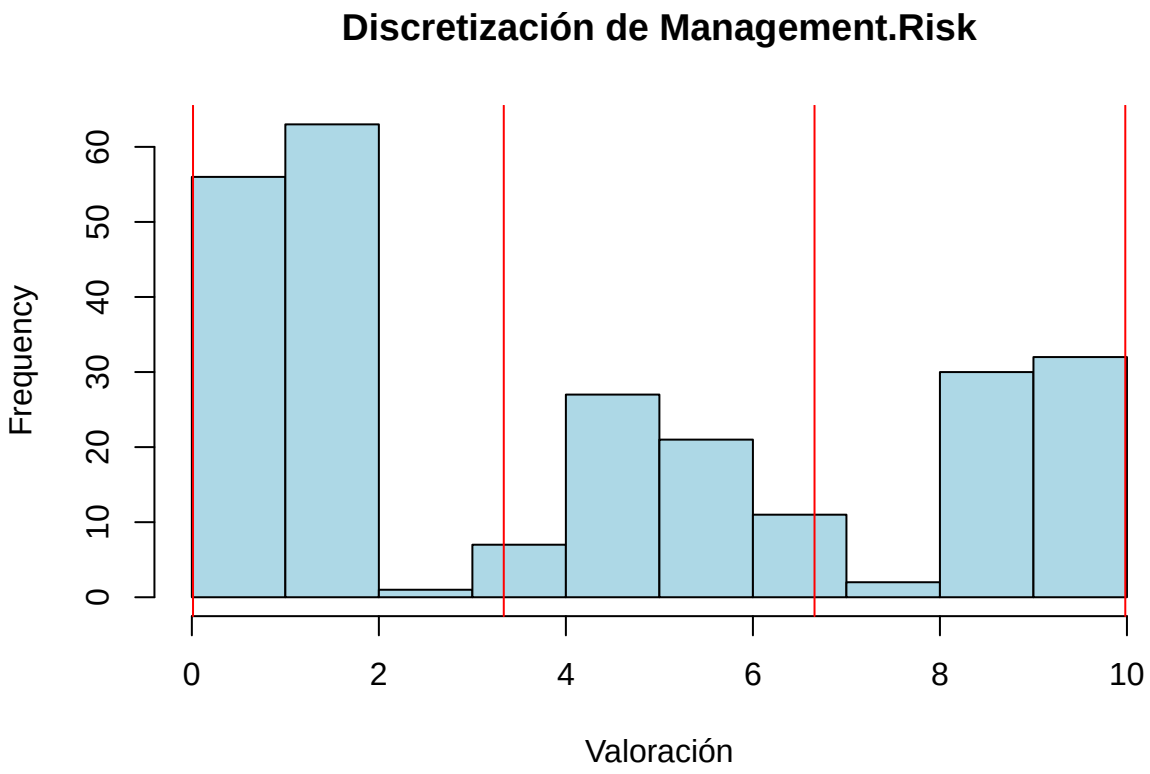
Discretización de Management.Risk
Frequency
0
10
20
30
40
50
60
0
2
4
6
8
10
Valoración

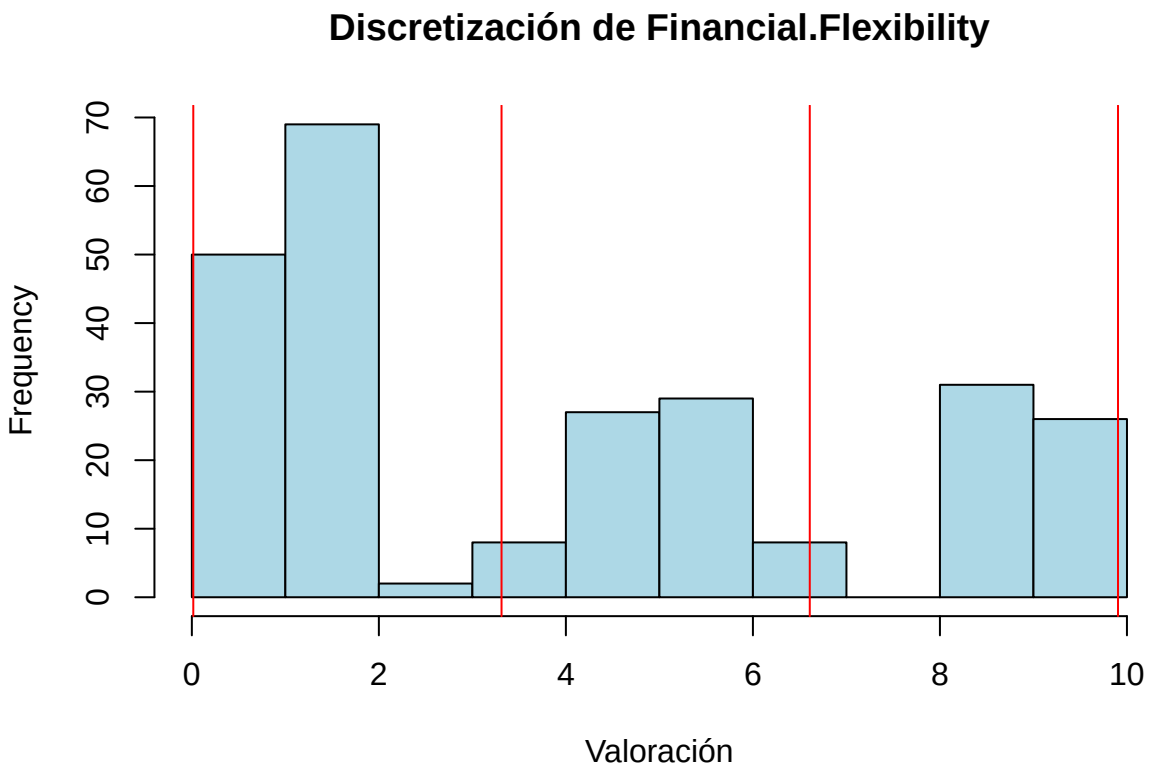
Discretización de Financial.Flexibility
Frequency
0
10
20
30
40
50
60
70
0
2
4
6
8
10
Valoración

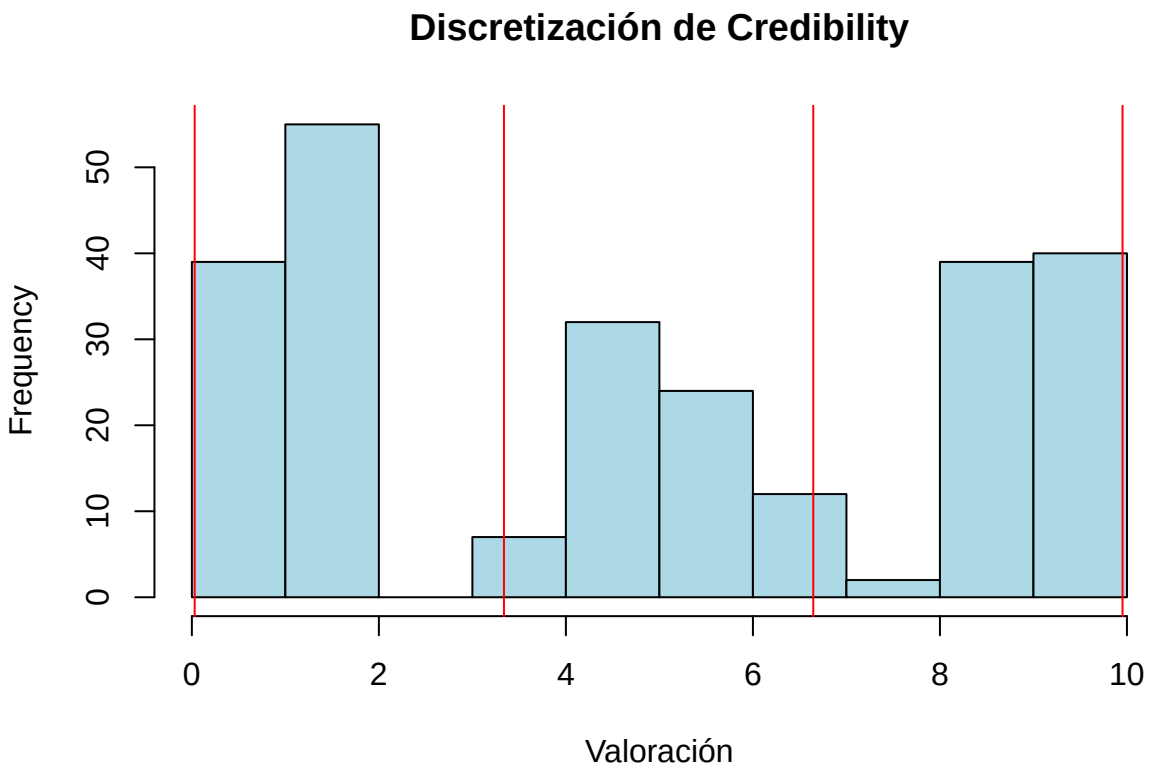
Discretización de Credibility
Frequency
0
10
20
30
40
50
0
2
4
6
8
10
Valoración

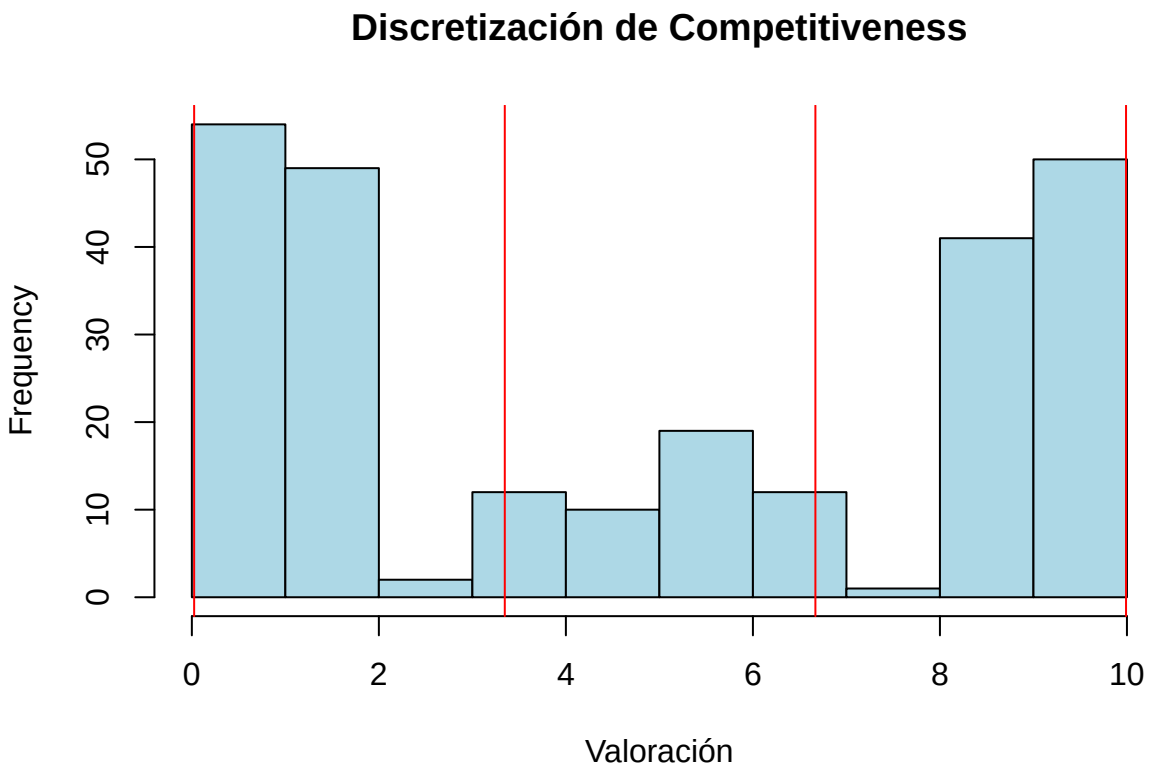
Discretización de Competitiveness
Frequency
0
10
20
30
40
50
0
2
4
6
8
10
Valoración

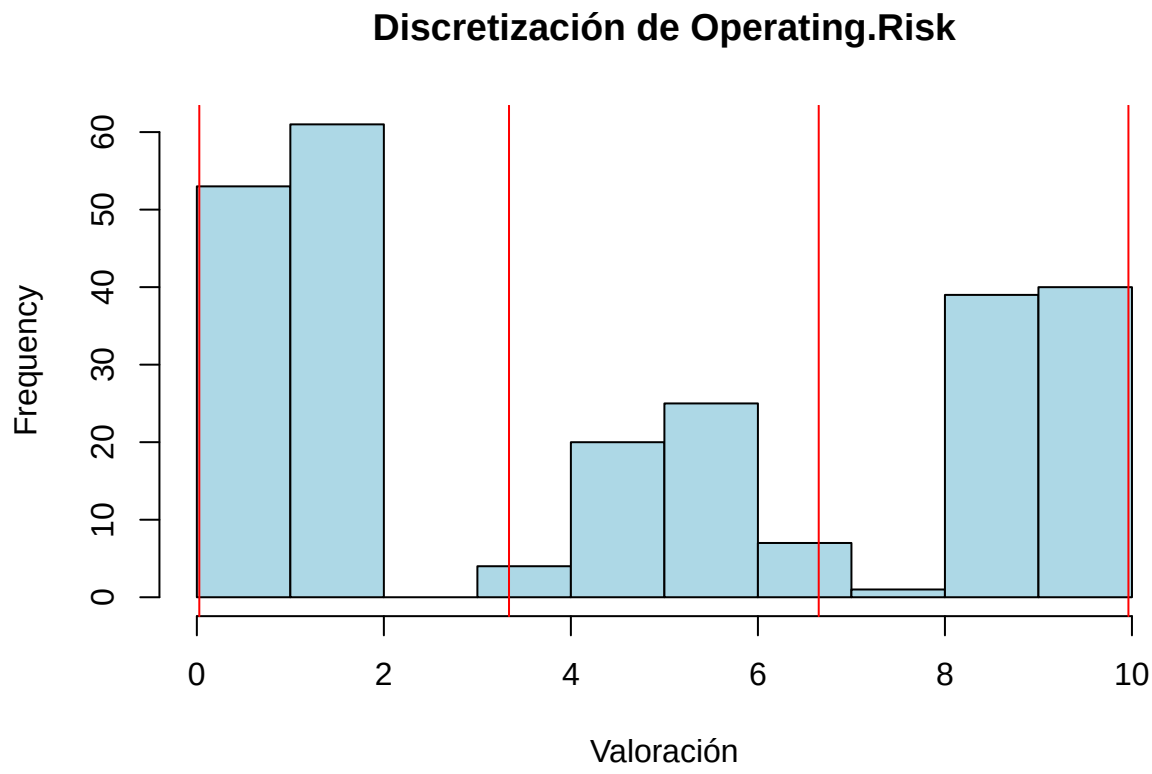


```
# Aplicamos la discretización a las columnas de una copia del df
QB_disc <- QB

QB_disc[, cols_num] <- lapply(QB[, cols_num], function(x) {
  # Asignamos las etiquetas en los intervalos correspondientes
  val_disc <- discretize(x, method = "interval", breaks = 3, labels = c("N", "A", "P"))

  # Garantizamos que son factores ordenados con N < A < P
  ordered(val_disc, levels = c("N", "A", "P"))
})
```

Asegúrate que toda las variables son factores de 3 niveles y ORDENADOS que respetan N<A<P. La clase `Bankruptcy` debe tener como primera etiqueta "B".

```
#solucion

# Verificamos que la estructura de "Bankruptcy" tenga "B" como primera etiqueta
QB_disc$Bankruptcy <- as.factor(QB_disc$Bankruptcy)
QB_disc$Bankruptcy <- relevel(QB_disc$Bankruptcy, ref = "B")

# Podemos ver que todas las variables numéricas aparecen como factores de 3 niveles ordenados (Ord.fact
str(QB_disc)
```

```
## spc_tbl_ [250 x 7] (S3: spec_tbl_df/tbl_df/tbl/data.frame)
##  $ Industrial.Risk      : Ord.factor w/ 3 levels "N"<"A"<"P": 3 1 2 3 1 2 3 3 3 3 ...
```

```
##  $ Management.Risk      : Ord.factor w/ 3 levels "N"<"A"<"P": 3 1 2 3 1 2 3 3 3 3 ...
##  $ Financial.Flexibility: Ord.factor w/ 3 levels "N"<"A"<"P": 2 2 2 3 3 3 2 3 2 1 ...
##  $ Credibility          : Ord.factor w/ 3 levels "N"<"A"<"P": 2 2 2 3 3 3 3 2 3 2 ...
##  $ Competitiveness      : Ord.factor w/ 3 levels "N"<"A"<"P": 2 2 2 3 3 3 3 2 2 3 ...
##  $ Operating.Risk       : Ord.factor w/ 3 levels "N"<"A"<"P": 3 1 2 3 1 2 3 3 3 3 ...
##  $ Bankruptcy           : Factor w/ 2 levels "B","NB": 2 2 2 2 2 2 2 2 2 2 ...
##  - attr(*, "spec")=
##   .. cols(
##   ..   X1 = col_double(),
##   ..   X2 = col_double(),
##   ..   X3 = col_double(),
##   ..   X4 = col_double(),
##   ..   X5 = col_double(),
##   ..   X6 = col_double(),
##   ..   X7 = col_character()
##   .. )
##  - attr(*, "problems")=<externalptr>
```

Análisis Cualitativo

Realiza un estudio del conjunto discretizado para determinar si es apropiado para resolver el problema (estimar Bankruptcy con el menor número de errores) .

Análisis univariante de las variables Cualitativas

Obtén la descripción de las variables incluida la clase. Al menos, se debe obtener la tabla de frecuencias y un gráfico para mostrar la frecuencias.

```r
#solucion

# Resumimos las variables rápidamente para ver cómo se distribuyen los datos
summary(QB_disc)
```

```
##  Industrial.Risk Management.Risk Financial.Flexibility Credibility
##  N:94            N:121           N:123                 N:96
##  A:74            A: 65           A: 67                 A:69
##  P:82            P: 64           P: 60                 P:85
##  Competitiveness Operating.Risk Bankruptcy
##  N:108           N:114          B :107
##  A: 50           A: 53          NB:143
##  P: 92           P: 83
```

```r
# Tablas de frecuencias relativas y absolutas
for (nombre in names(QB_disc)) {
  cat("\n---", nombre, "---\n")
  frec_abs <- table(QB_disc[[nombre]])
  frec_rel <- prop.table(frec_abs)

  # Juntamos ambas en una matriz para que se lea mejor
  print(rbind(Absoluta = frec_abs, Relativa = round(frec_rel, 3)))
}
```

```
##
## --- Industrial.Risk ---
##                N      A      P
## Absoluta 94.000 74.000 82.000
## Relativa  0.376  0.296  0.328
##
## --- Management.Risk ---
##                 N     A      P
## Absoluta 121.000 65.00 64.000
## Relativa   0.484  0.26  0.256
##
## --- Financial.Flexibility ---
##                 N      A     P
## Absoluta 123.000 67.000 60.00
## Relativa   0.492  0.268  0.24
##
## --- Credibility ---
##                N      A     P
## Absoluta 96.000 69.000 85.00
## Relativa  0.384  0.276  0.34
##
## --- Competitiveness ---
##                 N    A      P
## Absoluta 108.000 50.0 92.000
## Relativa   0.432  0.2  0.368
##
## --- Operating.Risk ---
##                 N      A      P
## Absoluta 114.000 53.000 83.000
## Relativa   0.456  0.212  0.332
##
## --- Bankruptcy ---
##                 B      NB
## Absoluta 107.000 143.000
## Relativa   0.428   0.572
```

```r
# Gráficos de barras
for (nombre in names(QB_disc)) {
  barplot(table(QB_disc[[nombre]]),
          main = nombre,
          ylab = "Frecuencia")
}
```

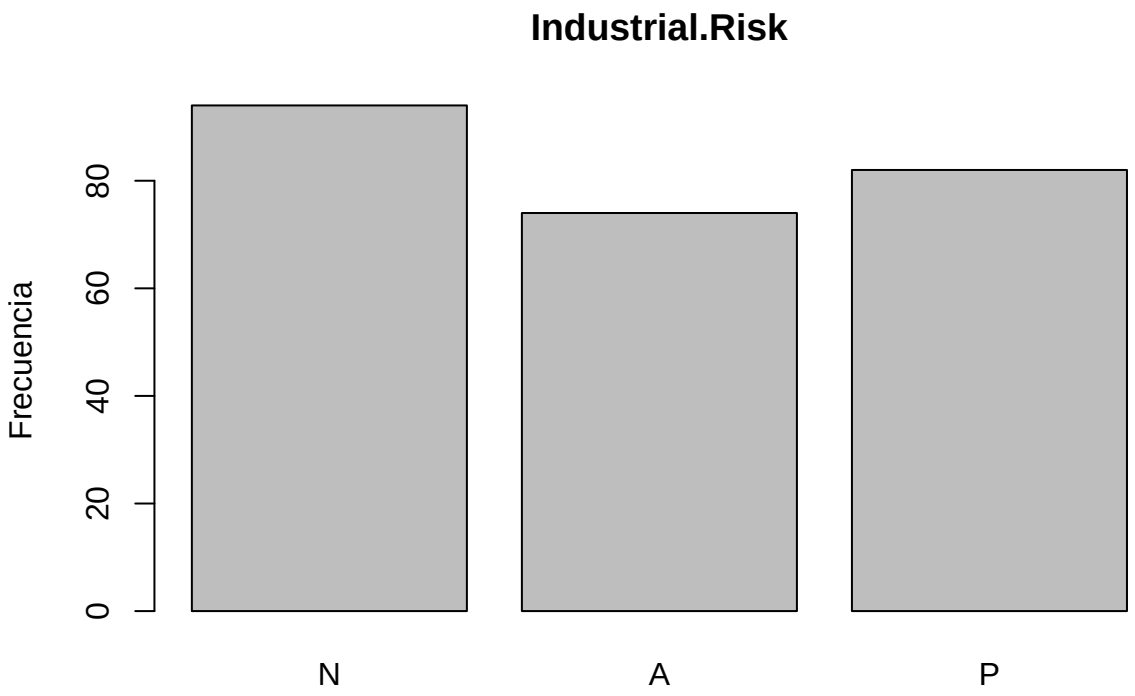
Industrial.Risk
Frecuencia
0
20
40
60
80
N
A
P

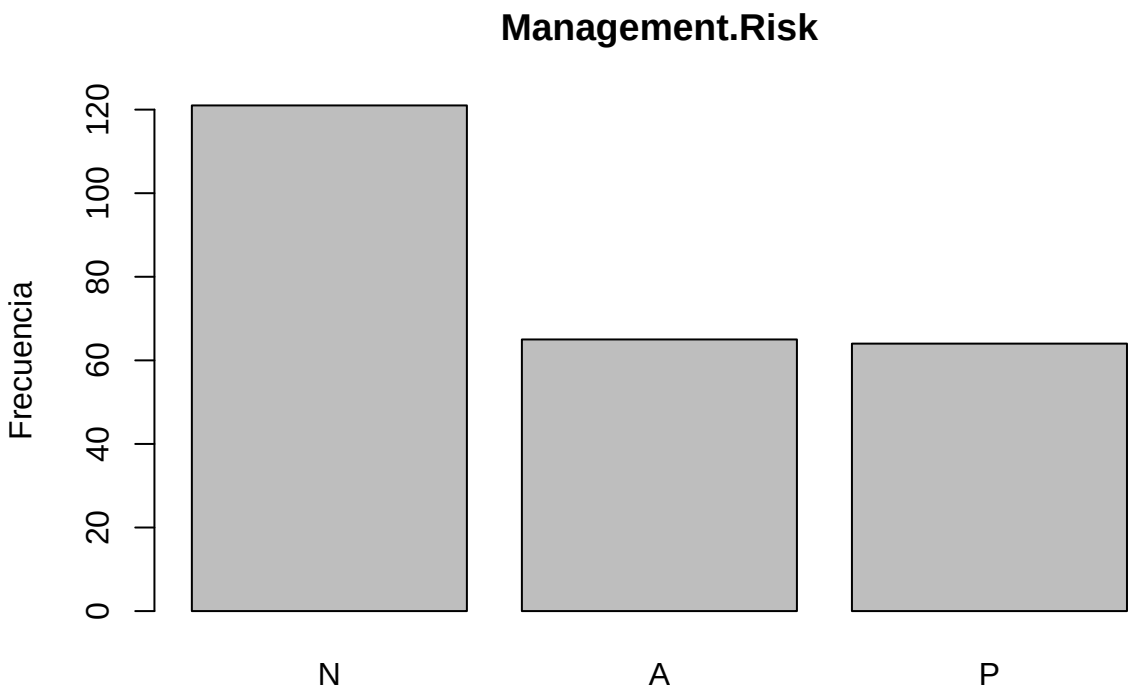
Management.Risk
Frecuencia
0
20
40
60
80
100
120
N
A
P

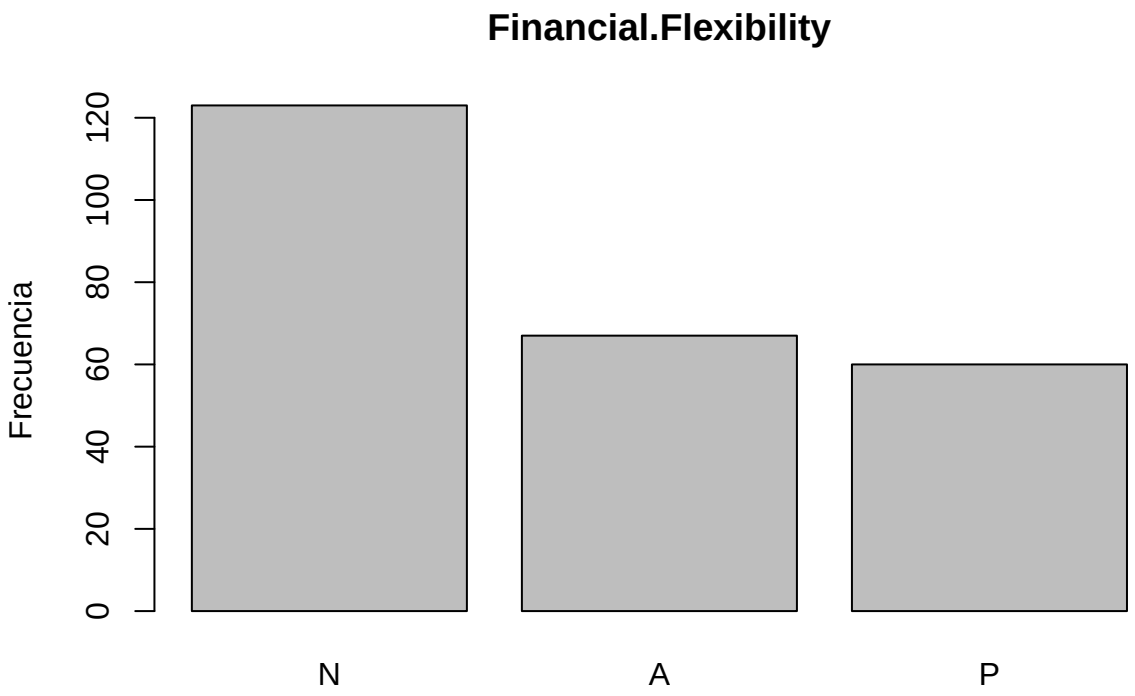
Financial.Flexibility
Frecuencia
0
20
40
60
80
100
120
N
A
P

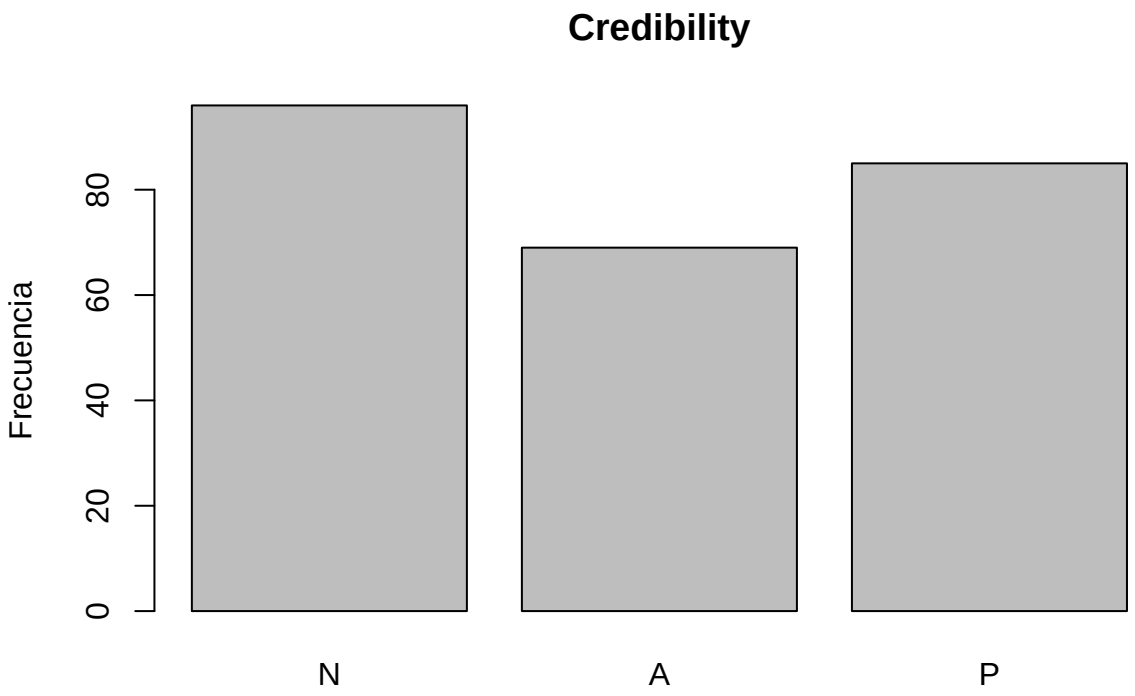
Credibility
Frecuencia
0
20
40
60
80
N
A
P

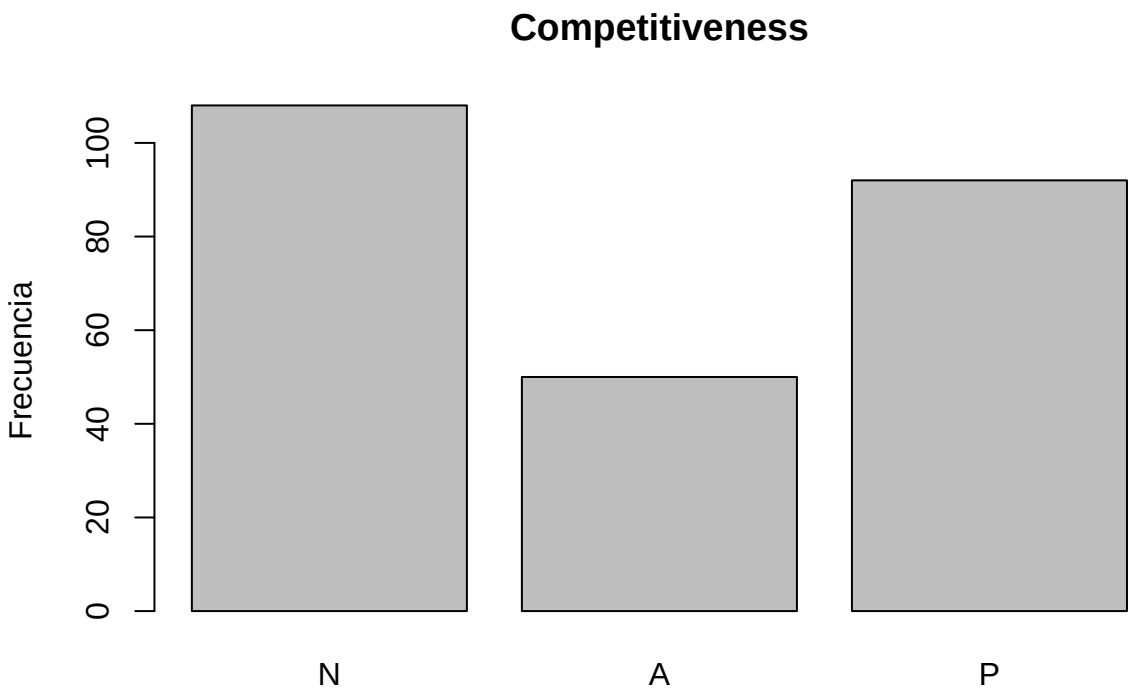
Competitiveness
Frecuencia
0
20
40
60
80
100
N
A
P

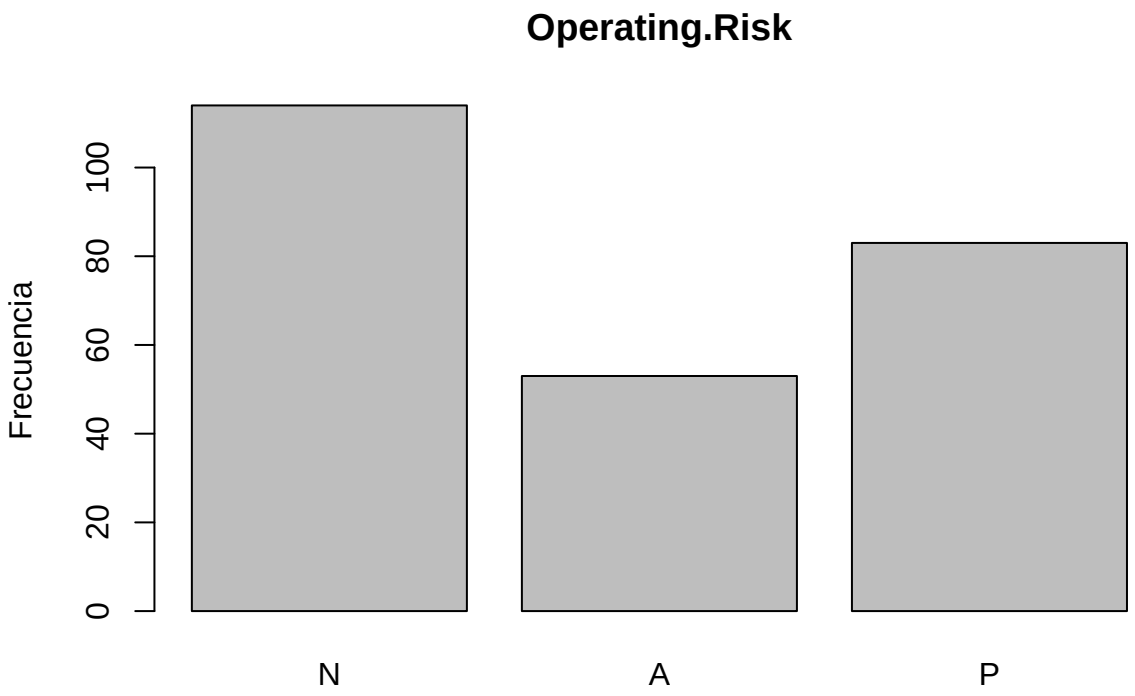
Operating.Risk
Frecuencia
0
20
40
60
80
100
N
A
P

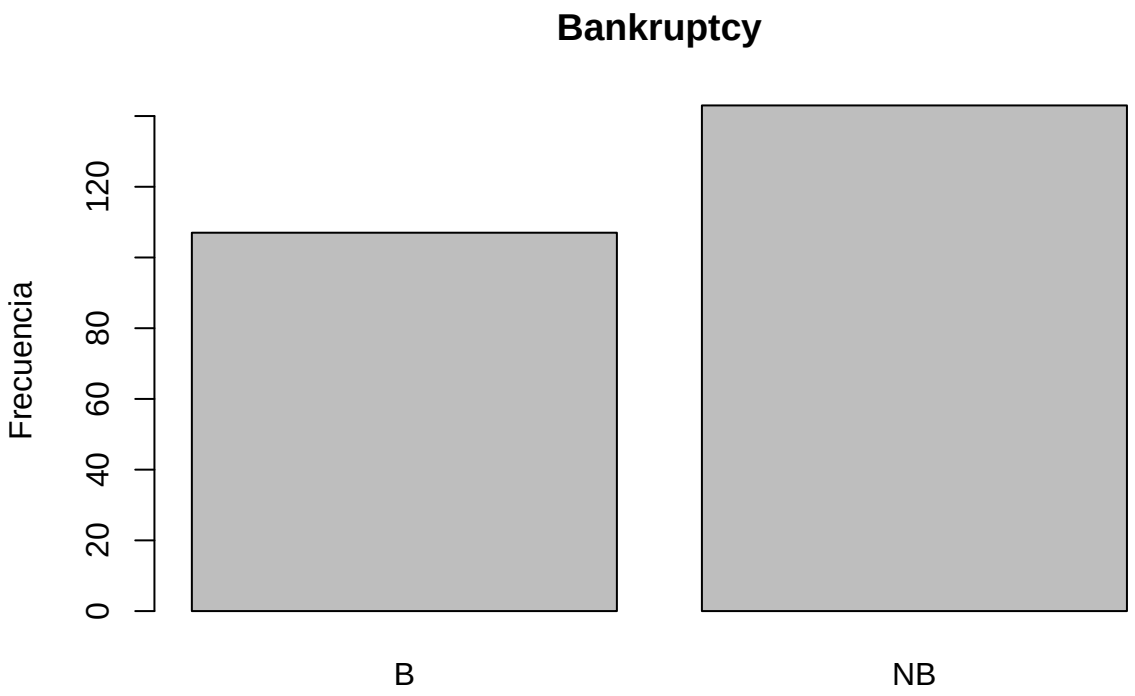

Describe, al menos, 2 conclusiones.

- Analizando la variable Bankruptcy, encontramos una proporción de 107 casos de bancarrota (42.8%) frente a 143 de no bancarrota (57.2%). Aunque el escenario ideal sería un equilibrio perfecto del 50%, esta distribución es lo suficientemente balanceada como para evitar que se produzcan sesgos significativos por la presencia mayoritaria de una clase a la hora de generar las reglas.
- En la gran mayoría de las variables predictoras, la categoría "A" (promedio) es la menos frecuente. Esto indica una tendencia en los expertos a evaluar los perfiles de las empresas de forma claramente negativa o positiva, evitando utilizar valoraciones intermedias.
- Las valoraciones negativas "N" son las más comunes en todas las variables. Esto resulta coherente con el alto número de empresas en bancarrota presentes en los datos (42.8%). Dado que una gran parte de las observaciones presentan factores de riesgo con valoración negativa, es esperable que un porcentaje significativo de estas termine quebrando.

»>«<Conclusiones del análisis univariante... »>«<

Análisis bivariante de las variables Cualitativas

Obtén la relación entre las variables y la clase (ej. matrices de contingencia). Determina el grado de asociación (ej. χ^2, CramerV, ...) entre cada variable y la clase.

Nota: La función PairApply de la librería DescTools permite calcular estadísticos para todos los pares. La función PlotCorr permite representar los resultados de PairApply.

```r
#solucion
library(DescTools)
```

```
## Warning: package 'DescTools' was built under R version 4.5.2
```

```r
# Hacemos una función que nos ayudará con el cálculo del test chi2, los argumentos (x, y) se espera que
Test_chi2 <- function(x,y){
  return(chisq.test(table(x,y))$p.value)
}

Pruebas_chi2 <- PairApply(QB_disc, Test_chi2)
PlotCorr(Pruebas_chi2)
```

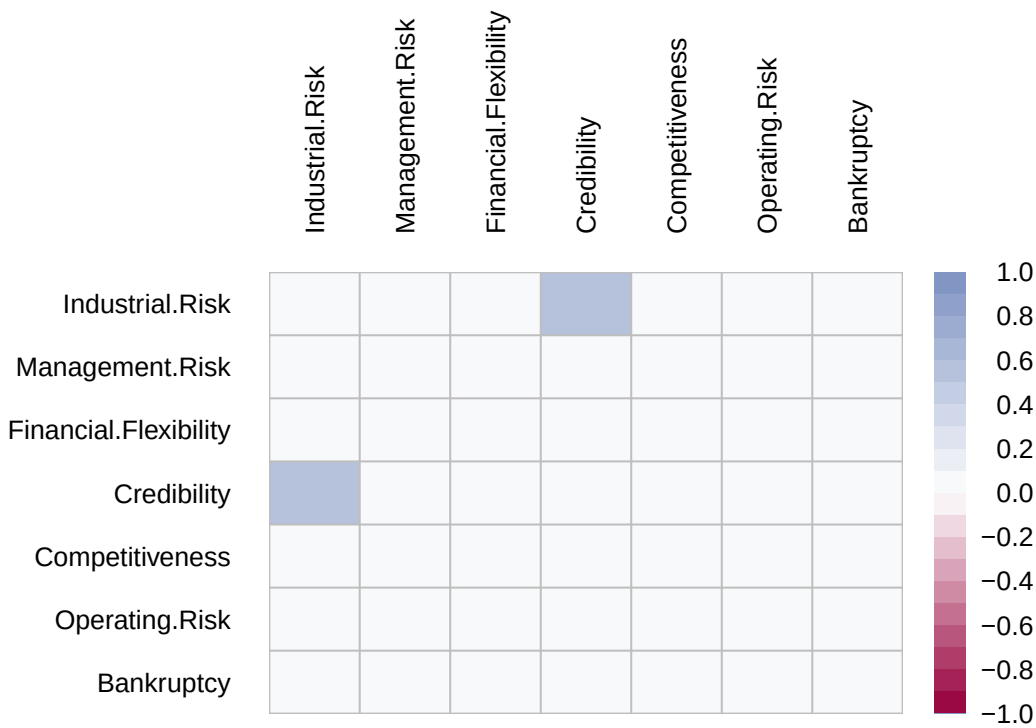

Óscar/2026−02−25

```r
V_de_Cramer <- PairApply(QB_disc, CramerV)
PlotCorr(V_de_Cramer)
```

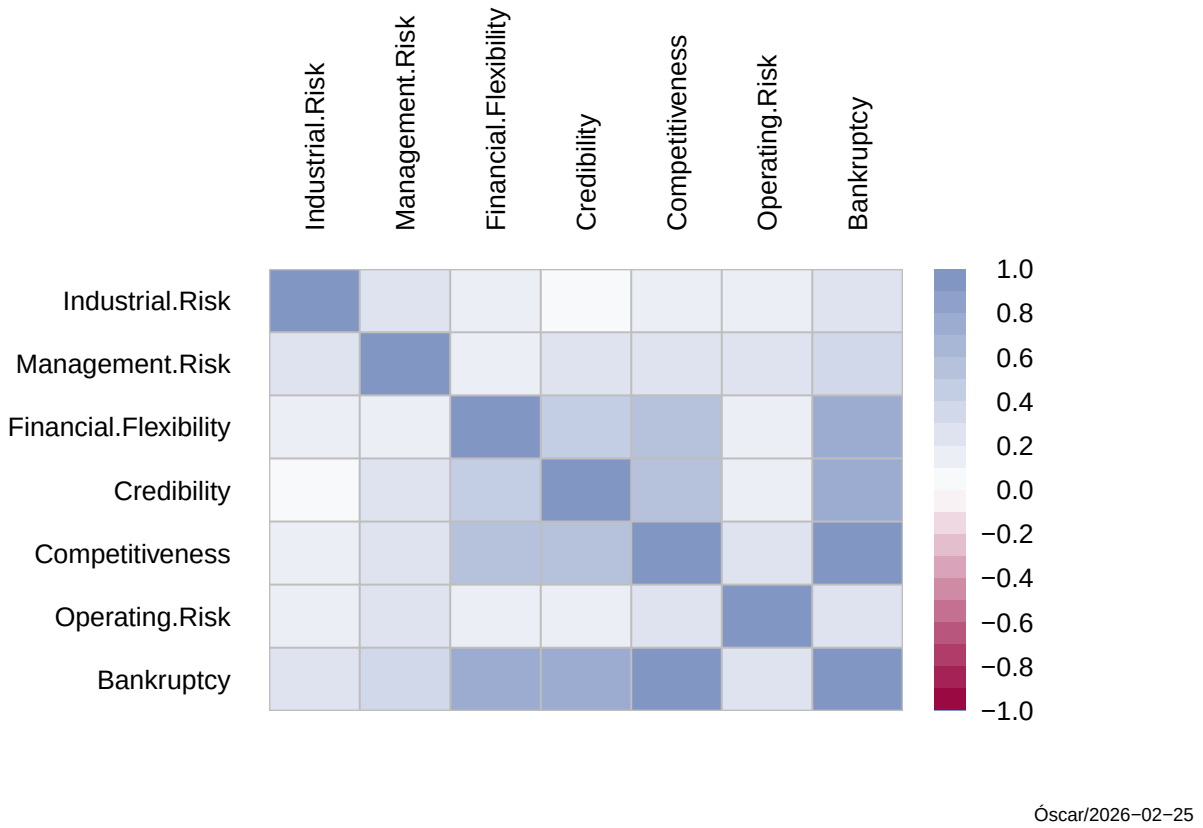

Contrasta los resultados con los gráficos de Mosaico de los casos más relevantes.

```
#solucion
library(vcd)
```

```
## Cargando paquete requerido: grid
```

```
tab1 <- mosaic(formula = ~ Industrial.Risk + Credibility, data=QB_disc, shade=T, main="Gráfico de mosai
```

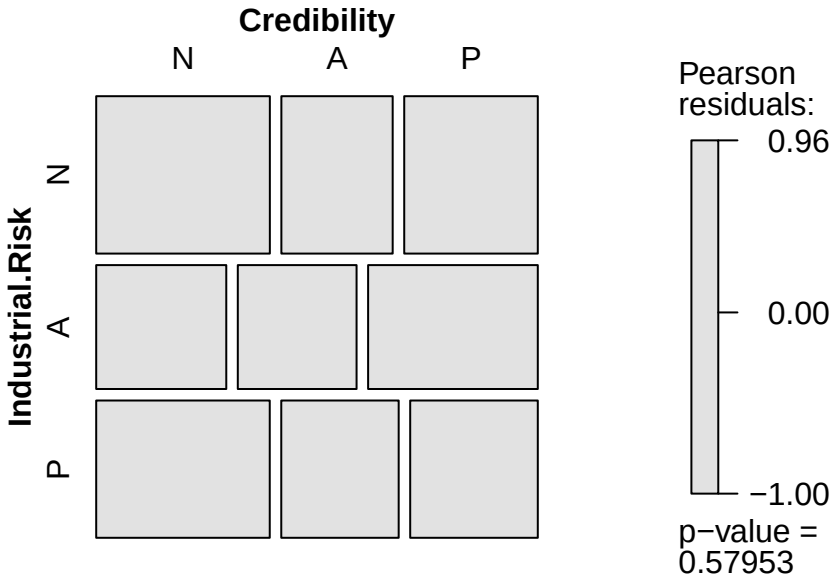


```
# Ahora los gráficos de mosaico para los pares de variables que tienen una dependencia (V de Cramer) ma
tab2 <- mosaic(formula = ~ Bankruptcy + Competitiveness, data=QB_disc, shade=T, main="Gráfico de mosaic
```

Gráfico de mosaico para las variables más dependientes

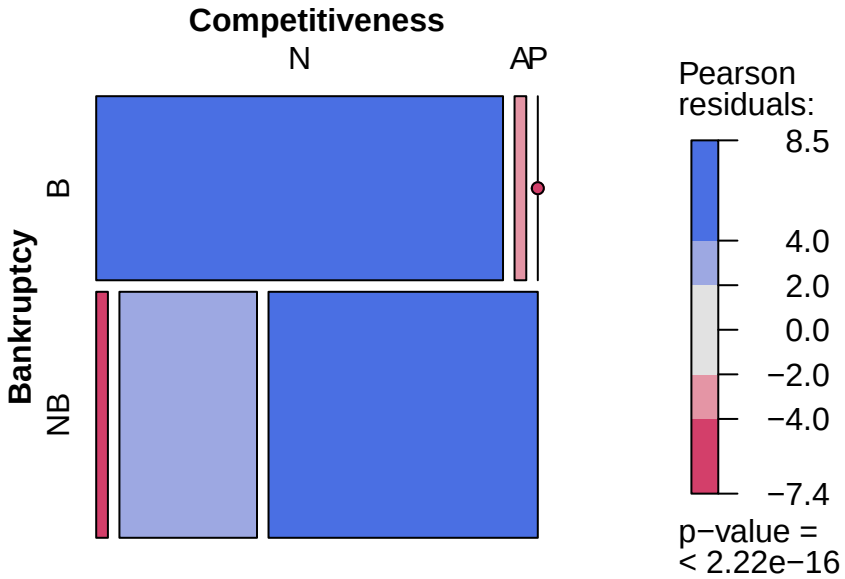


```
tab3 <- mosaic(formula = ~ Bankruptcy + Financial.Flexibility, data=QB_disc, shade=T, main="Gráfico de m
```

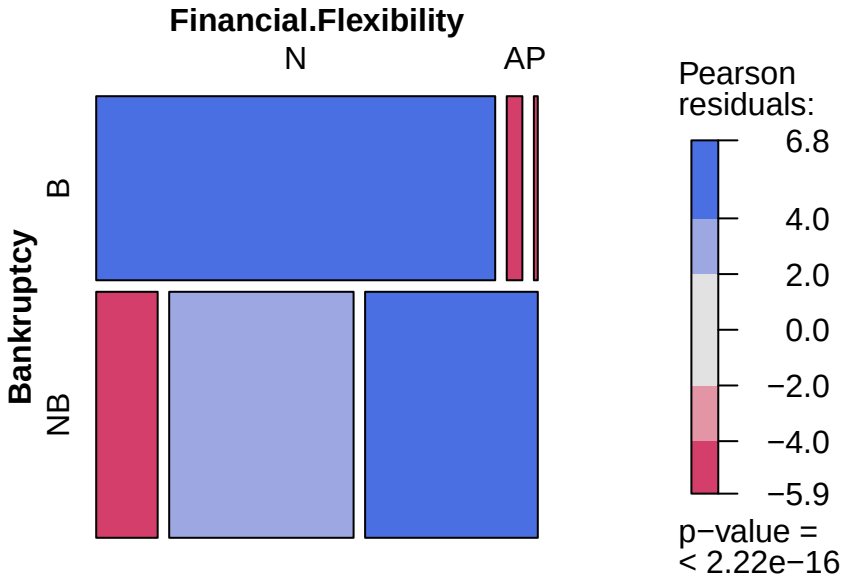

Describe, al menos, 2 conclusiones:

- Según el test χ^2 todas las variables discretizadas son dependientes una de otras (o al menos hay evidencia estadística suficiente para creerlo), con la única excepción de el par `Industrial.Risk` y `Credibility`, que es el único caso para el que el p-valor es menor que la significancia 0.05. Y además se observa en el diagrama de mosaico que aproximadamente todas las clases están igualmente repartidas, lo cual apoya la hipótesis de la independencia.
- En cambio, los pares de variables con mayor grado de asociación son los pares `Bankruptcy + Competitiveness` y `Bankruptcy + Financial.Flexibility`. Cosa que podemos confirmar visualmente en el diagrma de mosaico, donde por ejemplo podemos ver que las empresas menos competitivas acaban en bancarrota, mientras que aquellas que no llegaron a la bancarrota montraron un nivel intermedio o alto de competitividad.

»>«<**Conclusiones del análisis bivariante...** »>«<

Reglas de Asociación

Transforma el `data.frame` en *transactions* con el nombre `QBt` y analízalas con `summary`.

```
#solution
library(arules)

QBt <- as(QB_disc, "transactions")
summary(QBt)
```

```
## transactions as itemMatrix in sparse format with
##  250 rows (elements/itemsets/transactions) and
##  20 columns (items) and a density of 0.35
##
## most frequent items:
##          Bankruptcy=NB Financial.Flexibility=N       Management.Risk=N
##                    143                     123                     121
##       Operating.Risk=N       Competitiveness=N                 (Other)
##                    114                     108                    1141
##
## element (itemset/transaction) length distribution:
## sizes
##   7
## 250
##
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##       7       7       7       7       7       7
##
## includes extended item information - examples:
##              labels       variables levels
## 1 Industrial.Risk=N Industrial.Risk      N
## 2 Industrial.Risk=A Industrial.Risk      A
## 3 Industrial.Risk=P Industrial.Risk      P
##
## includes extended transaction information - examples:
##   transactionID
## 1             1
## 2             2
## 3             3
```

Obtén las reglas de asociación que tienen, al menos, un `support` del 10% y una `confidence` del 100%. ¿Cuántas reglas se obtienen?

```r
#solution
rules <- apriori(QBt, parameter = list(supp=0.1,
                                       conf=1,
                                       minlen=1,
                                       maxlen=10,
                                       target="rules"),
        control = list(verbose=T))
```

```
## Apriori
##
## Parameter specification:
##  confidence minval smax arem  aval originalSupport maxtime support minlen
##           1    0.1    1 none FALSE            TRUE       5     0.1      1
##  maxlen target  ext
##      10  rules TRUE
##
## Algorithmic control:
##  filter tree heap memopt load sort verbose
##     0.1 TRUE TRUE  FALSE TRUE    2    TRUE
##
## Absolute minimum support count: 25
```

```
##
## set item appearances ...[0 item(s)] done [0.00s].
## set transactions ...[20 item(s), 250 transaction(s)] done [0.00s].
## sorting and recoding items ... [20 item(s)] done [0.00s].
## creating transaction tree ... done [0.00s].
## checking subsets of size 1 2 3 4 5 6 done [0.00s].
## writing ... [81 rule(s)] done [0.00s].
## creating S4 object  ... done [0.00s].
```

Muestra las 3 primeras reglas ordenadas por `lift`.

```r
#solution
inspect(head(sort(rules, by = "lift"),n=3))
```

```
##     lhs                      rhs            support confidence coverage     lift count
## [1] {Industrial.Risk=N,
##      Credibility=N}      => {Bankruptcy=B}   0.156          1    0.156 2.336449    39
## [2] {Credibility=N,
##      Competitiveness=N}  => {Bankruptcy=B}   0.336          1    0.336 2.336449    84
## [3] {Management.Risk=N,
##      Competitiveness=N}  => {Bankruptcy=B}   0.280          1    0.280 2.336449    70
```

Obtén las reglas de asociación que tengan como **ANTECEDENTE** `Bankruptcy=B` . Reduce el número de reglas con las condiciones `lift>2 & count>50`. ¿Observas algún patrón/curiosidad en estas reglas?

Nota: Representar las reglas ayuda en la interpretación.

```r
#solucion
inspect(subset(rules, subset = lhs %ain% "Bankruptcy=B" & lift>2 & count>50))
```

```
##     lhs                           rhs                 support confidence coverage     lift count
## [1] {Industrial.Risk=N,
##      Bankruptcy=B}             => {Competitiveness=N}   0.220          1    0.220 2.314815    55
## [2] {Operating.Risk=N,
##      Bankruptcy=B}             => {Competitiveness=N}   0.256          1    0.256 2.314815    64
## [3] {Credibility=N,
##      Operating.Risk=N,
##      Bankruptcy=B}             => {Competitiveness=N}   0.216          1    0.216 2.314815    54
## [4] {Financial.Flexibility=N,
##      Operating.Risk=N,
##      Bankruptcy=B}             => {Competitiveness=N}   0.240          1    0.240 2.314815    60
```

Obtén las reglas de asociación en las que **no** aparezca la variable`Bankruptcy` (ni en el antecedente ni en la consecuencia). Representa las reglas. ¿Para qué sirven estas reglas/grafo si no aparece la variable objetivo?

```r
#solution
inspect(subset(rules, subset = !(lhs %pin% "Bankruptcy") & !(rhs %pin% "Bankruptcy")))
```

```
##     lhs                           rhs                 support confidence coverage     lift count
## [1] {Industrial.Risk=N,
##      Credibility=N}            => {Competitiveness=N}   0.156          1    0.156 2.314815    39
## [2] {Industrial.Risk=N,
```

```
##      Management.Risk=N,
##      Credibility=N}            => {Competitiveness=N}   0.112          1    0.112 2.314815    28
## [3] {Industrial.Risk=N,
##      Financial.Flexibility=N,
##      Credibility=N}            => {Competitiveness=N}   0.140          1    0.140 2.314815    35
## [4] {Industrial.Risk=N,
##      Management.Risk=N,
##      Financial.Flexibility=N}  => {Competitiveness=N}   0.156          1    0.156 2.314815    39
## [5] {Financial.Flexibility=N,
##      Credibility=N,
##      Operating.Risk=N}         => {Competitiveness=N}   0.200          1    0.200 2.314815    50
## [6] {Management.Risk=N,
##      Financial.Flexibility=N,
##      Operating.Risk=N}         => {Competitiveness=N}   0.140          1    0.140 2.314815    35
## [7] {Management.Risk=N,
##      Financial.Flexibility=N,
##      Credibility=N,
##      Operating.Risk=N}         => {Competitiveness=N}   0.116          1    0.116 2.314815    29
```

Primeramente nos podrían servir para saber que ciertas variables no son independientes unas de otras, aunque ya lo supiésemos por el análisis exploratorio inicial. Otra utilidad sería que estas relaciones nos ayudan a completar el grafo de reglas e implicaciones, sin estas reglas, aunque no incluyan la variable objetivo, las relaciones podrían estar incompletas y es posible que nos faltase información importante sobre los mecanismos mediante los cuales las diferentes variables afectan a la variable objetivo.

Predicción con reglas de asociación

Desarrolla un modelo de clasificación basado en reglas de asociación para estimar la Bancarrota. Comprueba la bondad del modelo (sensibilidad y especificidad) dividiendo el conjunto de datos en Entrenamiento 80% y Test 20%. Utiliza la función `createDataPartition` y `confusionMatrix` del paquete `caret`.

```r
set.seed(666)
#solucion

#solucion
library(caret)
```

```
## Warning: package 'caret' was built under R version 4.5.2

## Cargando paquete requerido: ggplot2

## Cargando paquete requerido: lattice

##
## Adjuntando el paquete: 'caret'

## The following objects are masked from 'package:DescTools':
##
##     MAE, RMSE
```

```r
library(OneR)
```

```
## Warning: package 'OneR' was built under R version 4.5.2
```

```r
# Partición de los datos en entrenamiento y test
train_Index <- createDataPartition(QB_disc$Bankruptcy, times=1, p=0.8, list=F)
QB_train <- QB_disc[train_Index,]
QB_test <- QB_disc[-train_Index,]

modelo_Una_Regla <- OneR(Bankruptcy~., data=QB_train, verbose = F)
summary(modelo_Una_Regla)
```

```
##
## Call:
## OneR.formula(formula = Bankruptcy ~ ., data = QB_train, verbose = F)
##
## Rules:
## If Competitiveness = N then Bankruptcy = B
## If Competitiveness = A then Bankruptcy = NB
## If Competitiveness = P then Bankruptcy = NB
##
## Accuracy:
## 197 of 201 instances classified correctly (98.01%)
##
## Contingency table:
##           Competitiveness
## Bankruptcy    N    A    P Sum
##        B   * 84    2    0  86
##        NB     2 * 38 * 75 115
##        Sum   86   40   75 201
## ---
## Maximum in each column: '*'
##
## Pearson's Chi-squared test:
## X-squared = 185.26, df = 2, p-value < 2.2e-16
```

```r
#prediction_test <- factor(predict(modelo_Una_Regla, newdata=QB_test), levels = c("B", "NB"))
#table(prediction_test, QB_test$Bankruptcy)
```

```r
library(arulesCBA)
```

```
## Warning: package 'arulesCBA' was built under R version 4.5.2
```

```r
modelo_CBA <- CBA(Bankruptcy~.,
                  data=QB_train,
                  verbose = F,
                  parameter = list(supp=0.1,
                                   conf = 1,
                                   minlen = 1,
                                   maxlen = 10))
```

```r
prediction_CBA_test <- factor(predict(modelo_CBA, QB_test), levels = c("B", "NB"))
prediction_CBA_train <- factor(predict(modelo_CBA, QB_train), levels = c("B", "NB"))

table(prediction_CBA_test, QB_test$Bankruptcy)
```

```
##
## prediction_CBA_test  B NB
##                  B  21  0
##                  NB  0 28
```

```r
table(prediction_CBA_train, QB_train$Bankruptcy)
```

```
##
## prediction_CBA_train   B  NB
##                   B   85   0
##                   NB   1 115
```

Reflexiones sobre el modelo basado en reglas:

»>«<Conclusiones del modelo basado en reglas...»>«<

¿has utilizado todas las variables en el modelo y por qué?

¿has seleccionado reglas y por qué? ¿en base a qué criterio?